Factores asociados a la insatisfacción de clientes en el comercio electrónico: un enfoque de aprendizaje de máquina sobre los datos de Olist

Jaime Alexis Herrera, Julián Andrés Rodríguez y Camilo Marsel Cespedes

I. Descripción del problema

I-A. Contexto y utilidad del problema

En el ecosistema actual del comercio electrónico, la fidelización del cliente es un factor de vital importancia para el crecimiento y la obtención de ganancias por parte de estas plataformas. Olist, una de las mayores aplicaciones de comercio electrónico en Brasil que conecta a pequeñas y medianas empresas con consumidores en todo el país, se enfrenta a un desafío que es propio a su modelo de negocio a gran escala: la gestión de la experiencia del cliente frente a una alta variabilidad operativa y logística. A pesar del éxito en las ventas y la gran acogida por la comunidad, una proporción significativa de los clientes experimentan altos niveles de insatisfacción, reflejados en calificaciones bajas respecto al servicio prestado por la plataforma. Como se evidenció en la exploración preliminar, aproximadamente el 12,8 % de las órdenes entregadas presentan este nivel de rechazo, principalmente asociado a deficiencias logísticas como tiempos de entrega prolongados y discrepancias entre la fecha estimada y la fecha real de llegada del producto.

Este indicador no solo representa un cliente insatisfecho, sino que impacta directamente en las métricas de retención, incrementando la tasa de abandono y afectando la reputación de la marca frente a nuevos compradores. Tradicionalmente, la gestión de la insatisfacción en el comercio electrónico (y en muchos otros sectores del comercio) se basa en un proceso reactivo: la empresa interviene únicamente después de que el usuario ha dejado una reseña negativa o ha radicado una queja (PQRS), momento en el cual la relación comercial con el cliente ya está afectada y el riesgo de pérdida es demasiado alta.

El desarrollo de una solución basada en técnicas de Aprendizaje de Máquina (ML) resulta fundamental y altamente útil para transformar este enfoque reactivo en uno predictivo y proactivo que entregaría información útil a las empresas y plataformas digitales como Olist. Mediante el entrenamiento de algoritmos de clasificación supervisada, es posible identificar patrones en las variables operativas disponibles al momento de registrar la entrega (tiempos logísticos, valor del flete, cantidad de vendedores involucrados, métodos de pago y ubicación geográfica) y predecir, antes de que el cliente escriba su reseña, la probabilidad de que la orden resulte en una experiencia insatisfactoria.

Modelos y Simulación II, Departamento de Ingeniería de Sistemas, Universidad de Antioquia.

I-B. Base de datos

Utilizamos el *Brazilian E-Commerce Public Dataset* de Olist [1], disponible en Kaggle. La base original comprende 9 tablas relacionales con información de órdenes, clientes, productos, vendedores, reseñas y pagos; el detalle de cada tabla está en el repositorio del proyecto. Al cruzar las tablas y filtrar las órdenes entregadas con reseña, obtuvimos $95\,824$ muestras, una por orden, correspondientes a $92\,747$ clientes.

Construimos 30 variables de entrada por orden. Las variables logísticas y de tiempo incluyen los días desde la compra hasta la entrega, los días de retraso frente a la fecha prometida, el tiempo de despacho del vendedor y dos indicadores binarios de retraso. Las variables económicas recogen el precio total, el flete, su proporción sobre el precio, el valor pagado y el número de cuotas. Las variables del producto y geográficas comprenden el número de artículos, peso, volumen y fotos del producto, la distancia en kilómetros entre vendedor y comprador, y los estados geográficos de origen y destino. La variable objetivo es binaria: calificaciones 1 y 2 como insatisfecho (clase 1) y 3 a 5 como satisfecho (clase 0); el 12,8 % de las órdenes corresponde a la clase insatisfecha.

La calificación de 3 estrellas es ambigua, por lo que justificamos su ubicación del lado satisfecho con un análisis de sensibilidad. Las 7 916 órdenes de 3 estrellas (8,3 % del total) tienen un perfil operativo intermedio pero más cercano al de 4-5 que al de 1-2: su tasa de entregas tardías es del 11,0 %, frente al 29,3 % en las de 1-2 y el 3,5 % en las de 4-5. Un modelo de diagnóstico entrenado sin órdenes de 3 estrellas mejora el AUC-ROC en menos de 0,01, y esa mejora desaparece al evaluarlo sobre todas las órdenes, que es el escenario de uso real. Moverlas al lado insatisfecho (definición alternativa) reduce el AUC-ROC en cerca de 0,05. Mantenemos el corte 1-2 contra 3-5, que es además el mismo que usan los cuatro trabajos revisados en el estado del arte.

Solo el 1,92 % de los registros presentaba datos faltantes. Las variables de características del producto (peso, fotos, categoría y nombre) tenían un 1,4 % de nulos por vendedores que no completaron esos campos; los numéricos se imputaron con la mediana y la categoría recibió la etiqueta “Desconocido”. El 0,5 % carecía de distancia por códigos postales sin coordenadas, imputado también con la mediana. Adicionalmente, 1.343 registros (1,4 %) mostraban la fecha de despacho anterior a la aprobación del pago, error corregido igualando esa diferencia a cero. En todos los casos la mediana se calcula solo con el pliegue de entrenamiento para evitar fuga

de información.

Las variables numéricas con distribución asimétrica (precio, peso, flete y distancia) reciben una transformación $\log(1+x)$ seguida de estandarización Z-score. Las variables binarias conservan sus valores 0 y 1. Las variables categóricas se codifican con *one-hot*: para estados geográficos y categorías de producto se retienen los 15 niveles más frecuentes y los demás se agrupan en "otros".

I-C. Análisis exploratorio

El factor con mayor correlación empírica con la insatisfacción es el cumplimiento de la promesa de entrega (Fig. 1). Mientras el pedido llegue dentro de la fecha estimada, la tasa de clientes insatisfechos oscila entre el 9 % y el 11 %. En cambio, al acumular cuatro días de retraso, la insatisfacción supera el 60 %. A nivel global, el 8 % de las órdenes sufrió retrasos, y dentro de este grupo la insatisfacción trepa al 54,1 %, frente al 9,2 % registrado en entregas puntuales. Otro patrón revelador aparece en órdenes que involucran a dos vendedores: la insatisfacción alcanza el 46 % frente al 12 % en órdenes de un solo vendedor. Nuestra hipótesis es que estas compras llegan en envíos separados y el cliente califica negativamente al recibir solo una parte del pedido.

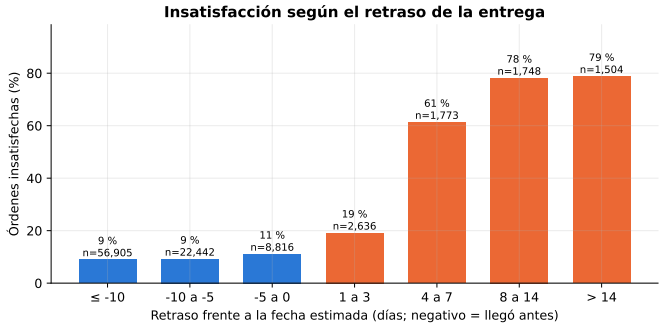


Figura 1. Porcentaje de órdenes insatisfechas según el retraso de la entrega frente a la fecha estimada. Los valores negativos indican que la orden llegó antes.

A lo largo del tiempo, la insatisfacción ronda el 10 % durante casi todo el periodo, pero sube en noviembre de 2017 (16,6 %), coincidiendo con Black Friday, y en febrero y marzo de 2018 (19,4 % y 21,2 %). Son meses de alto volumen de compras donde sospechamos que la logística se congestiona.

Evaluamos también si una mala experiencia en la primera compra castiga la recompra en la plataforma. Contrario a lo esperado, los datos no evidencian un impacto detectable: el 97 % de los usuarios compra exactamente una vez, y la tasa de recompra entre clientes satisfechos (3,0 %) y descontentos (2,8 %) no difiere con significancia estadística (χ^2, $p = 0{,}28$). Con un volumen tan bajo de recompras históricas, el conjunto de datos no ofrece base empírica para modelar retención a largo plazo, por lo que este aspecto se mantiene como una premisa de negocio respaldada en un estudio externo [2].

I-D. Paradigma de aprendizaje y justificación

El problema se resuelve con un paradigma de clasificación binaria supervisada. Elegimos aprendizaje supervisado porque los datos de Olist ya contienen la etiqueta real: el modelo aprende directamente de las reseñas históricas sin necesidad de inferir la señal.

Optamos por una formulación binaria y no por regresión ni clasificación multiclase porque el negocio necesita alertas claras, no predicciones de puntaje exacto. Predecir si una orden recibirá 3 o 4 estrellas no cambia la decisión operativa; predecir que recibirá 1 o 2 sí lo hace. Además, Wangkiat y Polprasert [3] muestran que los modelos multiclase obtienen un F_1 macro de solo 0,32 en este escenario, porque es difícil separar los matices entre calificaciones adyacentes. Siguiendo a los cuatro trabajos de la sección anterior, agrupamos 1 y 2 estrellas como "insatisfecho" (clase 1) y 3 a 5 como "satisfecho" (clase 0).

Como los datos están desbalanceados (solo el 12,8 % de las órdenes son insatisfechas), evaluar con exactitud global es engañoso: un modelo que clasifique todo como satisfecho acertaría el 87,2 % sin detectar ningún caso de riesgo. Por eso usamos el F_1 de la clase insatisfecha como métrica principal, junto con el AUC-ROC y el AUC-PR. Durante el entrenamiento, comparamos pesos por clase y SMOTE aplicado solo dentro de los pliegues para manejar el desbalance.

II. Estado del arte

Revisamos cuatro trabajos que predicen la satisfacción o la retención de clientes con los datos de Olist (Tabla I). Los cuatro plantean una clasificación supervisada binaria, y tres usan el mismo corte que nosotros, 1–2 estrellas contra 3–5. Wong y Marikannan [4] compararon árboles de decisión, bosque aleatorio, redes neuronales y SVM con 20 y con 5 variables, y probaron submuestreo, sobremuestreo, SMOTE y ROSE contra el desbalance. El bosque aleatorio obtuvo la mejor exactitud (87,6 %), pero detectó solo el 29,5 % de los clientes insatisfechos y ninguna técnica de balanceo mejoró esa cifra. Zaghloul et al. [5] seleccionaron variables por información mutua y compararon regresión logística, SVM, bosque aleatorio, *gradient boosting* y un perceptrón multicapa. Reportan 92 % de exactitud y AUC-ROC de 0,90 con bosque aleatorio y sobremuestreo, pero sus métricas están ponderadas por la frecuencia de cada clase y quedan dominadas por la mayoritaria. Orman [6] evaluó ocho modelos clásicos y cinco redes profundas con partición estratificada 80/20 y SMOTE aplicado solo al entrenamiento, y es el único que reporta por separado las métricas de la clase insatisfecha: su mejor red (GRU-LSTM) llega a 86,1 % de exactitud con una sensibilidad de 14,4 %, un F_1 de 0,24 y un AUC-ROC de 0,56 en esa clase. Zeinali et al. [2] predicen el abandono a 180 días por cliente con regresión logística, bosque aleatorio y XGBoost, y encuentran que la calificación promedio del cliente es la segunda variable más importante, lo que conecta la insatisfacción con la pérdida de clientes.

Dos cosas de esta revisión cambiaron nuestro diseño. La primera es que una exactitud alta puede convivir con un modelo que casi no detecta a los insatisfechos: con 12,8 % de positivos, un modelo que marque todas las órdenes como satisfechas tiene 87,2 % de exactitud. Por eso evaluamos con métricas de la clase insatisfecha (sección III-A). La segunda

Tabla I
TRABAJOS PREVIOS SOBRE SATISFACCIÓN Y RETENCIÓN DE CLIENTES CON LOS DATOS DE OLIST

Trabajo	Paradigma	Técnicas	Validación	Métricas	Mejor resultado
Wong y Marikannan [4]	Supervisado, binario (1–2 vs. 3–5)	Árbol de decisión, RF, red neuronal, SVM; 20 vs. 5 variables; submuestreo, sobremuestreo, SMOTE, ROSE	50 % de los datos; partición 70/30; RF con validación cruzada de 1 a 5 pliegues	Exactitud, sensibilidad, especificidad, F_1, tiempo	RF: exactitud 87,6 %, F_1 0,93, especificidad 29,5 %. El balanceo no mejoró la especificidad
Zaghloul et al. [5]	Supervisado, binario (1–2 vs. 3–5)	Regresión logística, SVM, RF, *gradient boosting*, MLP; selección por información mutua; sobremuestreo aleatorio, SMOTE, ADASYN	Partición aleatoria 67/33 por artículo; búsqueda en malla	Exactitud, AUC-ROC, AUC-PR, precisión, sensibilidad y F_1 ponderados	RF con sobremuestreo: exactitud 92 %, F_1 ponderado 0,92, AUC-ROC 0,90
Orman [6]	Supervisado, binario (1–2 vs. 3–5)	8 modelos clásicos (RL, NB, árboles, RF, XGBoost, LightGBM, CatBoost) y 5 profundos (CNN, RNN, MLP, GRU-LSTM, LSTM-GRU)	Partición estratificada 80/20; validación cruzada estratificada de 3 pliegues para los clásicos; SMOTE solo en entrenamiento	Exactitud con IC de Wilson, precisión, sensibilidad y F_1 por clase, F_1 macro y ponderado, exactitud balanceada, MCC, AUC-ROC, AUC-PR	GRU-LSTM: exactitud 86,1 %, pero sensibilidad de 14,4 % y F_1 de 0,24 en la clase insatisfecha; AUC-ROC 0,56
Zeinali et al. [2]	Supervisado, binario (abandono a 180 días), por cliente; K-means para segmentar	K-means sobre RFM; RL, RF, XGBoost con pesos por clase	Partición estratificada 80/20; validación cruzada estratificada de 5 pliegues; variables calculadas antes de la fecha de corte	Exactitud, precisión, sensibilidad, F_1, AUC-ROC	XGBoost: exactitud 0,81, F_1 0,81, AUC-ROC 0,85. La calificación promedio es la segunda variable más importante

es la unidad de análisis. Zaghloul et al. partieron los datos por artículo, de modo que artículos de una misma orden, con la misma fecha de entrega y la misma calificación, pueden quedar unos en entrenamiento y otros en prueba, y parte de su desempeño puede venir de esa fuga. Nosotros partimos por orden. En lo que sí coinciden los cuatro trabajos es en que las variables de entrega son las más predictivas, igual que en nuestro análisis exploratorio.

III. ENTRENAMIENTO Y EVALUACIÓN DE LOS MODELOS

III-A. Configuración experimental

El modelo opera en la ventana entre el registro de la entrega y la recepción de la reseña; variables como el retraso frente a la fecha prometida solo existen en ese momento, por lo que el sistema no es aplicable al instante de la compra. Separamos el 20 % de las órdenes (19 165) como conjunto de prueba, estratificado por la etiqueta, y no lo usamos hasta comparar los modelos ya ajustados. Con el 80 % restante (76 659 órdenes) elegimos los hiperparámetros por búsqueda en malla con validación cruzada estratificada de 5 pliegues. El preprocesamiento de la sección I-B va dentro de un *pipeline* de scikit-learn, así que la mediana de imputación, los parámetros del escalado y los 15 niveles que conserva cada variable categórica salen del pliegue de entrenamiento, nunca del de validación ni del de prueba.

La métrica principal es el F_1 de la clase insatisfecha, la media armónica entre la sensibilidad (qué fracción de los clientes insatisfechos detecta el modelo) y la precisión (qué fracción de las alertas son correctas). Como depende del umbral de decisión, en cada pliegue de la búsqueda en malla usamos el umbral que la maximiza. Para el modelo final fijamos el umbral con las predicciones fuera de pliegue del entrenamiento y lo aplicamos sin cambios a prueba. Reportamos además el AUC-ROC, la probabilidad de que el modelo asigne más riesgo a una orden insatisfecha que a una satisfecha, y el AUC-PR, el área bajo la curva de precisión contra sensibilidad, que es más exigente cuando la clase positiva es poco frecuente. Los intervalos de confianza del 95 % de validación salen de la t de Student sobre los 5 pliegues, y los de prueba de 1 000 remuestreos bootstrap. Cabe señalar que en la búsqueda en malla el umbral se optimiza sobre el mismo pliegue de validación que luego se usa para medir el F_1, lo que puede inflar levemente ese valor; el umbral del modelo final se fija sobre predicciones fuera de pliegue, donde este sesgo no aplica.

Contra el desbalance usamos pesos inversos a la frecuencia de cada clase en los modelos que los admiten. En la regresión logística los comparamos con no corregir y con SMOTE aplicado solo dentro de los pliegues de entrenamiento. Con el umbral ajustado, el F_1 casi no cambia (0,457 sin corregir, 0,464 con pesos y 0,463 con SMOTE), pero el AUC-ROC sube de 0,733 a 0,747 con pesos, sin traslape de intervalos. Pesos y SMOTE dieron lo mismo y nos quedamos con los pesos, que no agregan filas sintéticas. KNN y la red neuronal no aceptan pesos, y en ellos el ajuste del umbral cumple esa función.

Comparamos seis modelos: regresión logística (paramétrico), K vecinos más cercanos (no paramétrico), una máquina de vectores de soporte con kernel gaussiano, dos ensambles de árboles (bosque aleatorio y *gradient boosting* con histogramas)

Tabla II
HIPERPARÁMETROS EXPLORADOS EN CADA MODELO. EN NEGRITA, LA MEJOR CONFIGURACIÓN

Modelo	Hiperparámetro	Valores
Regresión logística	C	**0,001**; 0,01; 0,1; 1; 10
	penalización	**L2**; L1
KNN	vecinos k	5; 15; 35; 75; **151**; 301
	ponderación	uniforme; **distancia**
SVM (RBF)	C	**0,1**; 1; 10
	γ	0,003; **0,01**; 0,03
Bosque aleatorio (300 árboles)	profundidad máx.	8; **16**; sin límite
	mín. órdenes por hoja	1; 10; **50**
	variables por división	$\sqrt{d}$; **30 %**
Gradient boosting	tasa de aprendizaje	0,03; **0,1**; 0,3
	máx. hojas por árbol	15; **31**; 63
	regularización L2	0; **1**
Red neuronal (ReLU, Adam)	capas ocultas	(32); (128); **(64, 32)**; (128, 64)
	regularización α	10^{-4}; 10^{-3}; $\mathbf{10^{-2}}$

y un perceptrón multicapa. La Tabla II resume las mallas. Entrenamos la SVM con una submuestra estratificada de 16 000 órdenes porque su costo crece más que cuadráticamente con el número de muestras; su evaluación en prueba sí usa el conjunto completo. El *gradient boosting* y la red usan parada temprana con el 10 % del pliegue de entrenamiento.

III-B. Resultados

La Fig. 2 muestra cómo cambia el F_1 con los hiperparámetros. La regresión logística y la red casi no sobreajustan: sus curvas de entrenamiento y validación están juntas y la malla se mueve en menos de una centésima. En KNN el efecto es el esperado. Con pocos vecinos el modelo memoriza el entrenamiento (F_1 de 1 con ponderación por distancia) y valida mal (0,38 con $k = 5$), y la validación mejora a medida que crece k hasta aplanarse desde 75 vecinos. La SVM sobreajusta cuando sube C o γ: con $C = 10$ y $\gamma = 0{,}03$ llega a 0,887 en entrenamiento y cae a 0,372 en validación. En el bosque aleatorio, los árboles sin límite de profundidad y con hojas de una orden memorizan el entrenamiento y aun así validan en 0,47, porque promediar 300 árboles compensa la varianza de cada uno; exigir 50 órdenes por hoja reduce esa brecha y da el mejor resultado. El *gradient boosting* tiene la malla más plana (de 0,475 a 0,481), porque la parada temprana decide el número de árboles y controla el sobreajuste por su cuenta.

La Tabla III compara la mejor configuración de cada modelo en entrenamiento, validación y prueba. Los dos ensambles de árboles quedan arriba en todas las métricas, sin diferencia entre ellos: F_1 de 0,483 y 0,481 en prueba, AUC-ROC de 0,764 y 0,763 y AUC-PR de 0,483 y 0,481. En F_1 le sacan unas dos centésimas a los otros cuatro modelos y los intervalos se tocan; en AUC-PR la ventaja es más clara y los intervalos de la regresión logística y de los ensambles no se traslapan. Validación y prueba difieren en menos de 0,01 en todos los modelos, así que el umbral elegido fuera de pliegue se transfiere bien a órdenes nuevas. Las curvas ROC y de precisión-sensibilidad en prueba (Fig. 3) confirman el orden: los ensambles dominan sobre todo en la zona de alta precisión, que es la que importa si la empresa solo puede atender a una parte de las alertas.

Con el bosque aleatorio y el umbral elegido, la alerta encuentra al 45 % de los clientes que van a calificar con 1 o 2 estrellas, y 52 de cada 100 órdenes marcadas terminan mal calificadas, cuando al azar serían 13. Más de la mitad de los insatisfechos se le escapa al modelo. Las variables describen la entrega y la orden, pero no la calidad del producto ni si coincidía con lo anunciado, y una orden puede llegar a tiempo y aun así decepcionar al cliente.

REFERENCIAS

[1] Olist and A. Sionek, "Brazilian e-commerce public dataset by olist," Kaggle, 2018. [Online]. Available: https://www.kaggle.com/datasets/olistbr/brazilian-ecommerce

[2] M. Zeinali, L. Ramezani Asli, and M. A. Khalili, "Integrating business intelligence and CRM systems with a machine learning approach for predictive customer retention in e-commerce," *The Scientific World Journal*, vol. 2026, p. 1946904, 2026.

[3] P. Wangkiat and C. Polprasert, "Machine learning approach to predict e-commerce customer satisfaction score," in *Proc. Int. Conf. on Business and Industrial Research (ICBIR)*. IEEE, 2023.

[4] A.-N. Wong and B. P. Marikannan, "Optimising e-commerce customer satisfaction with machine learning," *Journal of Physics: Conference Series*, vol. 1712, p. 012044, 2020.

[5] M. Zaghloul, S. Barakat, and A. Rezk, "Predicting e-commerce customer satisfaction: Traditional machine learning vs. deep learning approaches," *Journal of Retailing and Consumer Services*, vol. 79, p. 103865, 2024.

[6] R. Orman, "Hybrid deep learning for e-commerce customer satisfaction classification," *Array*, vol. 31, p. 101153, 2026.

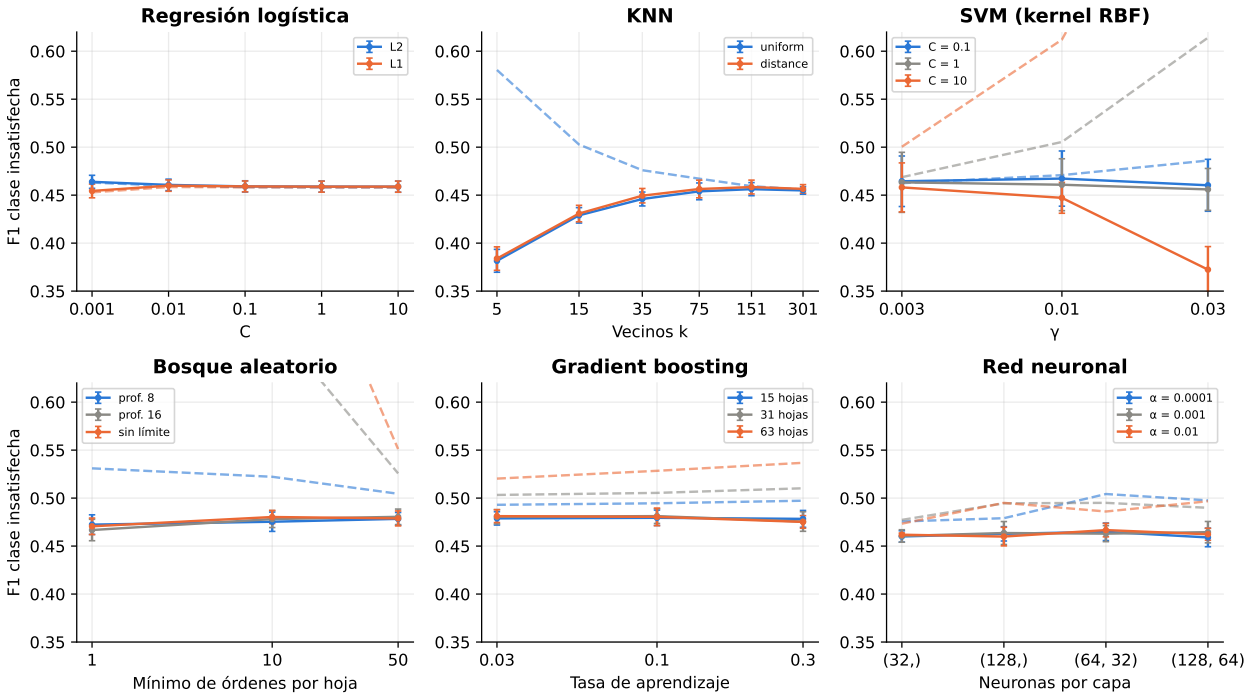


Figura 2. F_1 de la clase insatisfecha según los hiperparámetros de cada modelo. Línea continua: validación (media de 5 pliegues con intervalo de confianza del 95 %); línea discontinua: entrenamiento. En cada panel, los hiperparámetros que no aparecen están en su mejor valor.

Tabla III
DESEMPEÑO DE LA MEJOR CONFIGURACIÓN DE CADA MODELO. VALIDACIÓN: MEDIA DE 5 PLIEGUES ± SEMIANCHO DEL IC DEL 95 %. PRUEBA: VALOR PUNTUAL CON IC BOOTSTRAP DEL 95 %

	F_1 clase insatisfecha			Prueba	
Modelo	Entrenamiento	Validación	Prueba	AUC-ROC	AUC-PR
Regresión logística	0,463	0,464 ± 0,007	0,457 [0,439; 0,474]	0,751	0,418
KNN	1,000	0,458 ± 0,007	0,457 [0,439; 0,474]	0,743	0,437
SVM	0,471	0,467 ± 0,029	0,460 [0,443; 0,478]	0,754	0,435
Bosque aleatorio	0,526	0,480 ± 0,008	0,483 [0,466; 0,501]	0,764	0,483
Gradient boosting	0,505	0,481 ± 0,008	0,481 [0,463; 0,498]	0,763	0,481
Red neuronal	0,486	0,467 ± 0,007	0,464 [0,445; 0,480]	0,748	0,449

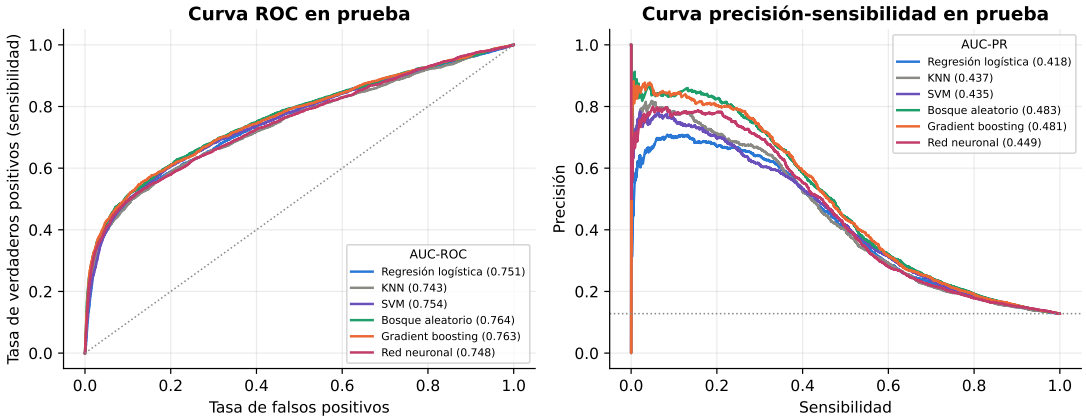


Figura 3. Curvas ROC (izquierda) y de precisión-sensibilidad (derecha) de los seis modelos en el conjunto de prueba. La línea punteada es un clasificador aleatorio.