Factores asociados a la insatisfacción de clientes en el comercio electrónico: un enfoque de aprendizaje de máquina sobre los datos de Olist

Jaime Alexis Herrera, Julián Andrés Rodríguez y Camilo Marsel Cespedes

***Resumen*—Olist, un marketplace brasileño, le pide a cada cliente que califique su compra de 1 a 5 estrellas cuando recibe el pedido, y el 12,8 % de las órdenes entregadas recibe 1 o 2. Construimos un clasificador que, en el momento en que se registra la entrega, estima la probabilidad de que la orden termine con una calificación así. Usamos 30 variables de la entrega, el pago, el producto y la ubicación de $95\,824$ órdenes de 2016 a 2018, y comparamos regresión logística, KNN, SVM, bosque aleatorio, *gradient boosting* y un perceptrón multicapa con validación cruzada estratificada y un conjunto de prueba aparte. La métrica principal es el F_1 de la clase insatisfecha. Los ensambles de árboles dan los mejores resultados en prueba (F_1 de 0,48, AUC-ROC de 0,76 y AUC-PR de 0,48), con una sensibilidad del 45 % y una precisión del 52 %. El análisis individual de variables permite quitar cinco de ellas sin perder desempeño, mientras que PCA y UMAP empeoran el modelo. El retraso frente a la fecha de entrega prometida es el factor más asociado a la insatisfacción.**

***Palabras clave*—Comercio electrónico, satisfacción del cliente, clasificación desbalanceada, aprendizaje supervisado, reducción de dimensión, Olist.**

I. Descripción del problema

I-A. Contexto y utilidad del problema

OLIST es un marketplace brasileño que conecta pequeños y medianos comerciantes con los grandes portales de comercio electrónico del país. Cuando una orden llega, Olist le envía al cliente una encuesta para calificar la compra de 1 a 5 estrellas. En los datos públicos de la empresa, el 12,8 % de las órdenes entregadas recibe 1 o 2 estrellas. Esa calificación baja la reputación del vendedor y la confianza de los compradores nuevos, y la empresa se entera tarde: cuando el cliente ya dejó la reseña o radicó una queja.

Proponemos un modelo que estime, en el momento en que se registra la entrega y antes de que el cliente califique, la probabilidad de que la orden termine con 1 o 2 estrellas. Con esa alerta, el equipo de servicio al cliente puede contactar primero a las órdenes de mayor riesgo, ofrecer una compensación o revisar al vendedor y a la transportadora. El vínculo entre insatisfacción y abandono que motiva el trabajo viene de un estudio externo [1]. En esta base no se puede verificar, porque el 97 % de los clientes compra una sola vez y la recompra no cambia entre satisfechos e insatisfechos (3,0 % frente a 2,8 %, prueba χ^2 con $p = 0{,}28$).

Modelos y Simulación II, Departamento de Ingeniería de Sistemas, Universidad de Antioquia.

I-B. Base de datos

Usamos el *Brazilian E-Commerce Public Dataset* que Olist publicó en Kaggle [2]: $99\,441$ órdenes hechas entre 2016 y 2018 y repartidas en nueve tablas relacionales (órdenes, artículos, pagos, reseñas, productos, clientes, vendedores, geolocalización y traducción de categorías). La unidad de análisis es la orden. Conservamos las órdenes entregadas que tienen fecha real de entrega y reseña, que son $95\,824$ de $92\,747$ clientes distintos; si una orden tiene varias reseñas tomamos la más reciente.

Por cada orden construimos 30 variables de entrada. Las de entrega miden los días entre la compra y la aprobación del pago, entre la aprobación y el despacho a la transportadora y entre la compra y la entrega, el plazo que Olist prometió, el retraso frente a ese plazo y dos indicadores de entrega tardía y de despacho tardío del vendedor. Las económicas son el precio, el flete, la razón entre flete y precio, el valor pagado, las cuotas y el número de medios de pago. Del producto tomamos el número de artículos, productos y vendedores, el peso, el volumen, las fotos y el largo de la descripción y del nombre. Completan la tabla la distancia entre cliente y vendedor (fórmula de haversine sobre las coordenadas del código postal), el mes, el día y la hora de compra, un indicador de si comprador y vendedor están en el mismo estado y cuatro variables categóricas: tipo de pago, categoría del producto (71 niveles), estado del cliente y estado del vendedor. La construcción y la descripción de cada variable están en el notebook `01_eda_olist.ipynb` del repositorio.

Los faltantes son pocos. El 1,4 % de las órdenes no tiene datos del producto porque el vendedor no los registró, y el 0,5 % no tiene distancia porque su código postal no está en la tabla de geolocalización. Imputamos los valores numéricos faltantes con la mediana del conjunto de entrenamiento y convertimos la categoría faltante en un nivel propio. En otras $1\,343$ órdenes la fecha de despacho a la transportadora es anterior a la aprobación del pago; es un error de registro y llevamos esa diferencia a cero.

A las variables numéricas con cola larga a la derecha (precio, flete, peso, volumen, distancia y días hasta el despacho) les aplicamos $\log(1 + x)$, y después estandarizamos todas las numéricas. Las binarias quedan en 0 y 1. Las categóricas las codificamos con *one-hot*. Para categoría y estados solo los 15 niveles más frecuentes en el conjunto de entrenamiento tienen columna propia, y el resto va a un nivel *Otros* que también recibe los niveles que aparezcan por primera vez en prueba.

El resultado son 79 columnas.

I-C. Hallazgos del análisis exploratorio

El retraso frente a la fecha prometida es lo que más se asocia con la insatisfacción. Entre las órdenes que llegan a tiempo hay de 9 % a 11 % de clientes insatisfechos; con uno a tres días de retraso la cifra sube a 19 % y desde cuatro días pasa del 60 %. El 8 % de las órdenes llega tarde, y en ese grupo la insatisfacción es de 54,1 %, frente a 9,2 % en las puntuales. Las órdenes con dos vendedores también salen mal calificadas (46 % frente a 12 %), probablemente porque llegan en envíos separados y el cliente califica cuando tiene solo una parte. En el tiempo, la tasa ronda el 10 % y sube en noviembre de 2017, mes del Black Friday (16,6 %), y en febrero y marzo de 2018 (19,4 % y 21,2 %), meses de mucho volumen. Precio, categoría, tipo de pago y estado aportan poco por sí solos.

I-D. Planteamiento de aprendizaje

Planteamos una clasificación binaria supervisada. Las calificaciones históricas dan la etiqueta: una orden es insatisfecha (clase 1) si recibió 1 o 2 estrellas y satisfecha (clase 0) si recibió de 3 a 5. Predecir el número exacto de estrellas, como regresión o con cinco clases, no le sirve más a la empresa, que necesita saber a quién atender primero, y además funciona mal: Wangkiat y Polprasert [3] obtienen un F_1 macro de 0,32 con cinco clases porque los modelos no distinguen 3 de 4 estrellas.

Las órdenes de 3 estrellas son el 8,3 % y su lugar no es obvio, porque pueden reflejar una experiencia neutra. Las dejamos en la clase satisfecha por lo que muestra la sección 10 del notebook de exploración. Su perfil logístico se parece más al de las órdenes de 4 y 5 estrellas: llegan tarde el 11,0 % de las veces, frente a 3,5 % de las de 4–5 y 33,8 % de las de 1–2. Un modelo entrenado sin ellas les asigna un riesgo medio de 0,16, cercano al de las de 4 estrellas (0,12) y lejos del de las de 2 (0,25). Excluirlas sube el AUC-ROC en menos de 0,01, con intervalos de confianza que se traslapan, mientras que pasarlas a la clase insatisfecha lo baja en 0,05. Es además el corte que usan los trabajos previos con estos datos [4], [5], [6], lo que permite comparar resultados.

Las variables de entrega solo se conocen cuando la orden llega, y por eso proponemos usar el modelo en ese momento, que es cuando Olist envía la encuesta. Con esa definición no hay fuga de información: ninguna variable usa datos posteriores a la entrega ni contenido de la reseña. Un sistema que alertara desde la compra no tendría las variables de entrega y sería un problema distinto.

II. Estado del arte

Revisamos cuatro artículos de revista que predicen la satisfacción o la retención de clientes con los datos de Olist (Tabla I). Los cuatro plantean una clasificación supervisada binaria, y tres usan el mismo corte que nosotros, 1–2 estrellas contra 3–5. Wong y Marikannan [4] compararon árboles de decisión, bosque aleatorio, redes neuronales y SVM con 20 y con 5 variables, y probaron submuestreo, sobremuestreo, SMOTE y ROSE contra el desbalance. El bosque aleatorio obtuvo la mejor exactitud (87,6 %), pero detectó solo el 29,5 % de los clientes insatisfechos y ninguna técnica de balanceo mejoró esa cifra. Zaghloul et al. [5] seleccionaron variables por información mutua y compararon regresión logística, SVM, bosque aleatorio, *gradient boosting* y un perceptrón multicapa. Reportan 92 % de exactitud y AUC-ROC de 0,90 con bosque aleatorio y sobremuestreo, pero sus métricas están ponderadas por la frecuencia de cada clase y quedan dominadas por la mayoritaria. Orman [6] evaluó ocho modelos clásicos y cinco redes profundas con partición estratificada 80/20 y SMOTE aplicado solo al entrenamiento, y es el único que reporta por separado las métricas de la clase insatisfecha: su mejor red (GRU-LSTM) llega a 86,1 % de exactitud con una sensibilidad de 14,4 %, un F_1 de 0,24 y un AUC-ROC de 0,56 en esa clase. Zeinali et al. [1] predicen el abandono a 180 días por cliente con regresión logística, bosque aleatorio y XGBoost, y encuentran que la calificación promedio del cliente es la segunda variable más importante, lo que conecta la insatisfacción con la pérdida de clientes.

Dos cosas de esta revisión cambiaron nuestro diseño. La primera es que una exactitud alta puede convivir con un modelo que casi no detecta a los insatisfechos: con 12,8 % de positivos, un modelo que marque todas las órdenes como satisfechas tiene 87,2 % de exactitud. Por eso evaluamos con métricas de la clase insatisfecha (sección III-A). La segunda es la unidad de análisis. Zaghloul et al. partieron los datos por artículo, de modo que artículos de una misma orden, con la misma fecha de entrega y la misma calificación, pueden quedar unos en entrenamiento y otros en prueba, y parte de su desempeño puede venir de esa fuga. Nosotros partimos por orden. En lo que sí coinciden los cuatro trabajos es en que las variables de entrega son las más predictivas, igual que en nuestro análisis exploratorio.

III. Entrenamiento y evaluación de los modelos

III-A. Configuración experimental

Separamos el 20 % de las órdenes (19 165) como conjunto de prueba, estratificado por la etiqueta, y no lo usamos hasta comparar los modelos ya ajustados. Con el 80 % restante (76 659 órdenes) elegimos los hiperparámetros por búsqueda en malla con validación cruzada estratificada de 5 pliegues. El preprocesamiento de la sección I-B va dentro de un *pipeline* de scikit-learn, así que la mediana de imputación, los parámetros del escalado y los 15 niveles que conserva cada variable categórica salen del pliegue de entrenamiento, nunca del de validación ni del de prueba.

La métrica principal es el F_1 de la clase insatisfecha, la media armónica entre la sensibilidad (qué fracción de los clientes insatisfechos detecta el modelo) y la precisión (qué fracción de las alertas son correctas). Como depende del umbral de decisión, en cada pliegue de la búsqueda en malla usamos el umbral que la maximiza. Para el modelo final fijamos el umbral con las predicciones fuera de pliegue del entrenamiento y lo aplicamos sin cambios a prueba. Reportamos además el AUC-ROC, la probabilidad de que el modelo asigne más riesgo a una orden insatisfecha que a una satisfecha, y el AUC-PR, el área bajo la curva de precisión contra sensibilidad, que

Tabla I
TRABAJOS PREVIOS SOBRE SATISFACCIÓN Y RETENCIÓN DE CLIENTES CON LOS DATOS DE OLIST

Trabajo	Paradigma	Técnicas	Validación	Métricas	Mejor resultado
Wong y Marikannan [4]	Supervisado, binario (1–2 vs. 3–5)	Árbol de decisión, RF, red neuronal, SVM; 20 vs. 5 variables; submuestreo, sobremuestreo, SMOTE, ROSE	50 % de los datos; partición 70/30; RF con validación cruzada de 1 a 5 pliegues	Exactitud, sensibilidad, especificidad, F_1, tiempo	RF: exactitud 87,6 %, F_1 0,93, especificidad 29,5 %. El balanceo no mejoró la especificidad
Zaghloul et al. [5]	Supervisado, binario (1–2 vs. 3–5)	Regresión logística, SVM, RF, *gradient boosting*, MLP; selección por información mutua; sobremuestreo aleatorio, SMOTE, ADASYN	Partición aleatoria 67/33 por artículo; búsqueda en malla	Exactitud, AUC-ROC, AUC-PR, precisión, sensibilidad y F_1 ponderados	RF con sobremuestreo: exactitud 92 %, F_1 ponderado 0,92, AUC-ROC 0,90
Orman [6]	Supervisado, binario (1–2 vs. 3–5)	8 modelos clásicos (RL, NB, árboles, RF, XGBoost, LightGBM, CatBoost) y 5 profundos (CNN, RNN, MLP, GRU-LSTM, LSTM-GRU)	Partición estratificada 80/20; validación cruzada estratificada de 3 pliegues para los clásicos; SMOTE solo en entrenamiento	Exactitud con IC de Wilson, precisión, sensibilidad y F_1 por clase, F_1 macro y ponderado, exactitud balanceada, MCC, AUC-ROC, AUC-PR	GRU-LSTM: exactitud 86,1 %, pero sensibilidad de 14,4 % y F_1 de 0,24 en la clase insatisfecha; AUC-ROC 0,56
Zeinali et al. [1]	Supervisado, binario (abandono a 180 días), por cliente; K-means para segmentar	K-means sobre RFM; RL, RF, XGBoost con pesos por clase	Partición estratificada 80/20; validación cruzada estratificada de 5 pliegues; variables calculadas antes de la fecha de corte	Exactitud, precisión, sensibilidad, F_1, AUC-ROC	XGBoost: exactitud 0,81, F_1 0,81, AUC-ROC 0,85. La calificación promedio es la segunda variable más importante

es más exigente cuando la clase positiva es poco frecuente. Los intervalos de confianza del 95 % de validación salen de la t de Student sobre los 5 pliegues, y los de prueba de 1 000 remuestreos bootstrap.

Contra el desbalance usamos pesos inversos a la frecuencia de cada clase en los modelos que los admiten. En la regresión logística los comparamos con no corregir y con SMOTE aplicado solo dentro de los pliegues de entrenamiento. Con el umbral ajustado, el F_1 casi no cambia (0,457 sin corregir, 0,464 con pesos y 0,463 con SMOTE), pero el AUC-ROC sube de 0,733 a 0,747 con pesos, sin traslape de intervalos. Pesos y SMOTE dieron lo mismo y nos quedamos con los pesos, que no agregan filas sintéticas. KNN y la red neuronal no aceptan pesos, y en ellos el ajuste del umbral cumple esa función.

Comparamos seis modelos: regresión logística (paramétrico), K vecinos más cercanos (no paramétrico), una máquina de vectores de soporte con kernel gaussiano, dos ensambles de árboles (bosque aleatorio y *gradient boosting* con histogramas) y un perceptrón multicapa. La Tabla II resume las mallas. Entrenamos la SVM con una submuestra estratificada de 16 000 órdenes porque su costo crece más que cuadráticamente con el número de muestras; su evaluación en prueba sí usa el conjunto completo. El *gradient boosting* y la red usan parada temprana con el 10 % del pliegue de entrenamiento.

Tabla II
HIPERPARÁMETROS EXPLORADOS EN CADA MODELO. EN NEGRITA, LA MEJOR CONFIGURACIÓN

Modelo	Hiperparámetro	Valores
Regresión logística	C	**0,001**; 0,01; 0,1; 1; 10
	penalización	**L2**; L1
KNN	vecinos k	5; 15; 35; 75; **151**; 301
	ponderación	uniforme; **distancia**
SVM (RBF)	C	**0,1**; 1; 10
	γ	0,003; **0,01**; 0,03
Bosque aleatorio (300 árboles)	profundidad máx.	8; **16**; sin límite
	mín. órdenes por hoja	1; 10; **50**
	variables por división	$\sqrt{d}$; **30 %**
Gradient boosting	tasa de aprendizaje	0,03; **0,1**; 0,3
	máx. hojas por árbol	15; **31**; 63
	regularización L2	0; **1**
Red neuronal (ReLU, Adam)	capas ocultas	(32); (128); **(64, 32)**; (128, 64)
	regularización α	10^{-4}; 10^{-3}; $\mathbf{10^{-2}}$

III-B. Resultados

La Fig. 1 muestra cómo cambia el F_1 con los hiperparámetros. La regresión logística y la red casi no sobreajustan: sus curvas de entrenamiento y validación están juntas y la malla se mueve en menos de una centésima. En KNN el efecto es el esperado. Con pocos vecinos el modelo memoriza el entrenamiento (F_1 de 1 con ponderación por distancia) y valida mal (0,38 con $k = 5$), y la validación mejora a medida que crece k hasta aplanarse desde 75 vecinos. La SVM sobreajusta cuando sube C o γ: con $C = 10$ y $\gamma = 0{,}03$ llega a 0,887

en entrenamiento y cae a 0,372 en validación. En el bosque aleatorio, los árboles sin límite de profundidad y con hojas de una orden memorizan el entrenamiento y aun así validan en 0,47, porque promediar 300 árboles compensa la varianza de cada uno; exigir 50 órdenes por hoja reduce esa brecha y da el mejor resultado. El *gradient boosting* tiene la malla más plana (de 0,475 a 0,481), porque la parada temprana decide el número de árboles y controla el sobreajuste por su cuenta.

La Tabla III compara la mejor configuración de cada modelo en entrenamiento, validación y prueba. Los dos ensambles de árboles quedan arriba en todas las métricas, sin diferencia entre ellos: F_1 de 0,483 y 0,481 en prueba, AUC-ROC de 0,764 y 0,763 y AUC-PR de 0,483 y 0,481. En F_1 le sacan unas dos centésimas a los otros cuatro modelos y los intervalos se tocan; en AUC-PR la ventaja es más clara y los intervalos de la regresión logística y de los ensambles no se traslapan. Validación y prueba difieren en menos de 0,01 en todos los modelos, así que el umbral elegido fuera de pliegue se transfiere bien a órdenes nuevas. Las curvas ROC y de precisión-sensibilidad en prueba (Fig. 2) confirman el orden: los ensambles dominan sobre todo en la zona de alta precisión, que es la que importa si la empresa solo puede atender a una parte de las alertas.

Con el bosque aleatorio y el umbral elegido, la alerta encuentra al 45 % de los clientes que van a calificar con 1 o 2 estrellas, y 52 de cada 100 órdenes marcadas terminan mal calificadas, cuando al azar serían 13. Más de la mitad de los insatisfechos se le escapa al modelo. Las variables describen la entrega y la orden, pero no la calidad del producto ni si coincidía con lo anunciado, y una orden puede llegar a tiempo y aun así decepcionar al cliente.

IV. Reducción de dimensión

Evaluamos tres formas de simplificar el modelo sobre los dos mejores de la sección anterior, *gradient boosting* y bosque aleatorio, con sus hiperparámetros fijos y el mismo protocolo de validación. Ajustamos la reducción dentro de cada pliegue, después del preprocesamiento.

IV-A. Análisis individual de variables

Para cada una de las 30 variables medimos, con el conjunto de entrenamiento, la información mutua con la etiqueta, que no supone una relación lineal y se aplica igual a numéricas y categóricas. La complementamos con el AUC univariado para numéricas y binarias, la V de Cramér para categóricas y la correlación de Spearman entre pares de variables numéricas para detectar redundancia. Las tres variables de entrega (retraso frente a lo prometido, días hasta la entrega e indicador de entrega tardía) tienen entre 0,044 y 0,057 nats, el doble que la siguiente, que es el número de vendedores de la orden (Fig. 3). Las categóricas aportan poco: ninguna pasa de 0,004 nats ni de 0,09 en la V de Cramér.

Marcamos como candidatas a eliminar las variables con información mutua menor que 0,001 nats y AUC univariado menor que 0,53, y la menos informativa de cada par con $|\rho_s| > 0{,}8$. Salen cinco: hora de compra, tipo de pago, cuotas, estado del vendedor y precio total, que es casi idéntico al valor pagado ($\rho_s = 0{,}99$). Como dos de ellas son categóricas, quitarlas elimina 24 de las 79 columnas. Ninguno de los dos modelos pierde desempeño sin ellas (Tabla IV).

IV-B. Extracción lineal: PCA

Tomamos el menor número de componentes principales que conserva el 95 % de la varianza del entrenamiento: 29 de 79, una reducción del 63 %. Es un criterio que no mira la etiqueta, así que la elección no se ajusta a los datos de validación. Con PCA el F_1 de validación baja de 0,48 a 0,46 en los dos modelos, sin traslape de intervalos con el espacio original. PCA conserva varianza y no capacidad de discriminar: buena parte de la varianza está en variables poco informativas como el precio, el peso o las columnas *one-hot*, y el retraso queda repartido entre varias componentes. Los árboles lo resienten, porque en el espacio original pueden cortar directamente sobre la entrega tardía.

IV-C. Extracción no lineal: UMAP

Para UMAP no hay una varianza explicada que sirva de criterio, así que elegimos el número de componentes por validación cruzada sobre una submuestra de $20\,000$ órdenes: el menor entre 2, 5, 10 y 20 cuyo F_1 cae dentro del intervalo de confianza del mejor. El F_1 no mejoró al agregar componentes y quedaron 2. Con todo el entrenamiento, los modelos sobre UMAP llegan a un F_1 de 0,36 a 0,37 en validación y su AUC-ROC en prueba baja a 0,61. UMAP no usa la etiqueta y conserva los vecindarios del espacio de 79 columnas, donde la distancia la dominan las columnas de categoría y estado; dos órdenes con el mismo producto y el mismo destino quedan cerca aunque una haya llegado a tiempo y la otra con diez días de retraso.

V. Discusión y conclusiones

El retraso de la entrega frente a la fecha prometida es lo que mejor anticipa una calificación de 1 o 2 estrellas. Lo mostró el análisis exploratorio, lo confirma el análisis individual de variables y coincide con los cuatro trabajos revisados. El modelo que proponemos, un *gradient boosting* con 25 variables, detecta en prueba al 44 % de los clientes que terminarán insatisfechos con una precisión del 53 %, cuatro veces la tasa base de 12,8 %. Los dos ensambles de árboles superan a los otros cuatro modelos, sobre todo en AUC-PR, y entre ellos los intervalos se traslapan por completo. La regresión logística queda solo dos centésimas de F_1 por debajo, lo que indica que la mayor parte de la señal es casi lineal y está concentrada en pocas variables.

Frente a la literatura, nuestro AUC-ROC de 0,76 es menor que el 0,90 de Zaghloul et al. [5], pero ellos partieron los datos por artículo y reportan métricas ponderadas por clase, dos decisiones que inflan el resultado. El trabajo comparable es el de Orman [6], que reporta las métricas de la clase insatisfecha: su mejor red obtiene un F_1 de 0,24 y una sensibilidad de 14,4 % en esa clase, y nuestro bosque aleatorio llega a 0,48 y 45 %. Wong y Marikannan [4] detectan al 29,5 % de los insatisfechos. La diferencia está en ajustar el umbral

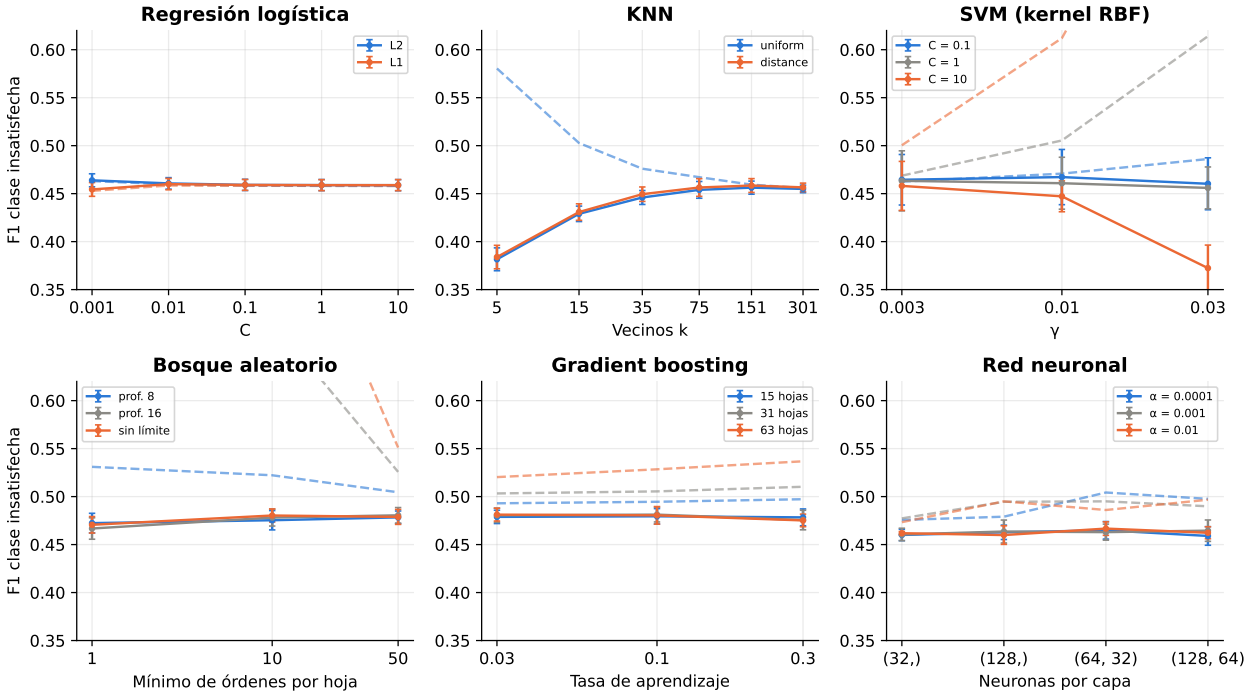


Figura 1. F_1 de la clase insatisfecha según los hiperparámetros de cada modelo. Línea continua: validación (media de 5 pliegues con intervalo de confianza del 95 %); línea discontinua: entrenamiento. En cada panel, los hiperparámetros que no aparecen están en su mejor valor.

Tabla III
DESEMPEÑO DE LA MEJOR CONFIGURACIÓN DE CADA MODELO. VALIDACIÓN: MEDIA DE 5 PLIEGUES ± SEMIANCHO DEL IC DEL 95 %. PRUEBA: VALOR PUNTUAL CON IC BOOTSTRAP DEL 95 %

	F_1 clase insatisfecha			Prueba	
Modelo	Entrenamiento	Validación	Prueba	AUC-ROC	AUC-PR
Regresión logística	0,463	0,464 ± 0,007	0,457 [0,439; 0,474]	0,751	0,418
KNN	1,000	0,458 ± 0,007	0,457 [0,439; 0,474]	0,743	0,437
SVM	0,471	0,467 ± 0,029	0,460 [0,443; 0,478]	0,754	0,435
Bosque aleatorio	0,526	0,480 ± 0,008	0,483 [0,466; 0,501]	0,764	0,483
Gradient boosting	0,505	0,481 ± 0,008	0,481 [0,463; 0,498]	0,763	0,481
Red neuronal	0,486	0,467 ± 0,007	0,464 [0,445; 0,480]	0,748	0,449

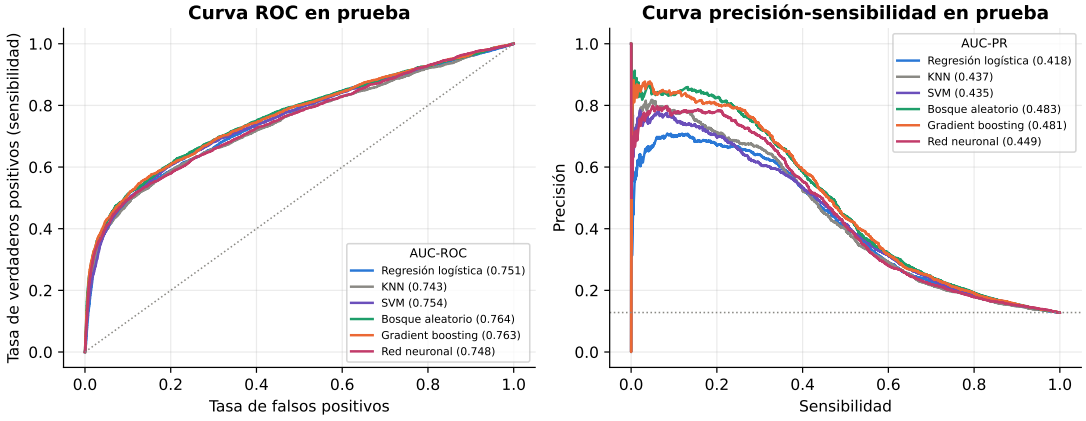


Figura 2. Curvas ROC (izquierda) y de precisión-sensibilidad (derecha) de los seis modelos en el conjunto de prueba. La línea punteada es un clasificador aleatorio.

de decisión para la clase minoritaria en vez de usar 0,5 y en seleccionar el modelo con una métrica de esa clase. En cuanto a la reducción de dimensión, quitar cinco variables poco informativas recorta el 30 % de las columnas sin pérdida,

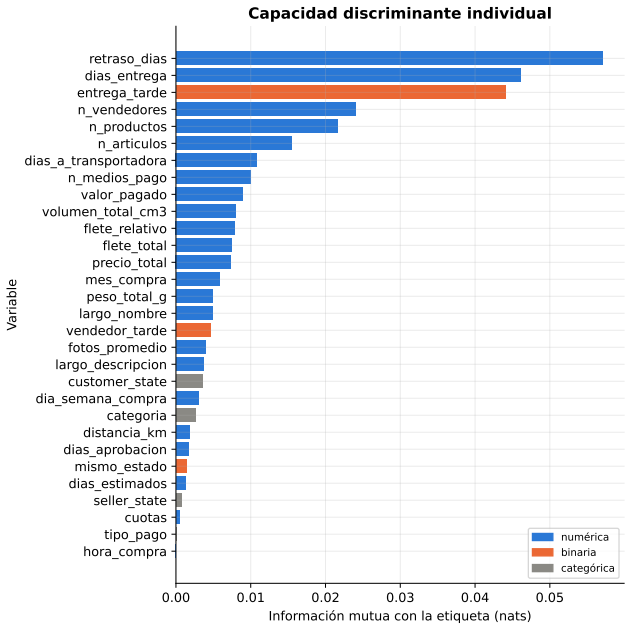


Figura 3. Información mutua de cada variable de entrada con la etiqueta, calculada en el conjunto de entrenamiento.

Tabla IV
DESEMPEÑO DE LOS DOS MEJORES MODELOS CON CADA REDUCCIÓN. REDUCCIÓN FRENTE A LAS 79 COLUMNAS DEL PREPROCESAMIENTO; F_1 DE LA CLASE INSATISFECHA EN VALIDACIÓN (MEDIA $\pm$ IC DEL 95 %) Y EN PRUEBA

Espacio	Dim. (red.)	F_1 val.	F_1 prueba	AUC-ROC
Gradient boosting				
Original	79 (0 %)	0,481 $\pm$ 0,008	0,481	0,763
Selección	55 (30 %)	0,480 $\pm$ 0,008	0,481	0,763
PCA	29 (63 %)	0,463 $\pm$ 0,010	0,469	0,755
UMAP	2 (97 %)	0,364 $\pm$ 0,017	0,388	0,612
Bosque aleatorio				
Original	79 (0 %)	0,480 $\pm$ 0,008	0,483	0,764
Selección	55 (30 %)	0,479 $\pm$ 0,008	0,477	0,763
PCA	29 (63 %)	0,464 $\pm$ 0,006	0,467	0,759
UMAP	2 (97 %)	0,371 $\pm$ 0,014	0,385	0,616

mientras que PCA y UMAP, que no usan la etiqueta, mezclan la señal de entrega con variables irrelevantes y empeoran el modelo.

El trabajo tiene límites. Las variables describen la operación, no el producto ni la atención al cliente, y más de la mitad de los insatisfechos no se pueden anticipar con ellas. El modelo se evaluó con una partición aleatoria; como la tasa de insatisfacción cambia en los meses de alto volumen, una validación temporal, entrenando con meses anteriores y evaluando con los siguientes, daría una estimación más realista para un despliegue. Por último, el beneficio para Olist depende de lo que haga con las alertas, y el vínculo entre insatisfacción y abandono no se puede medir en estos datos porque casi ningún cliente vuelve a comprar.

REFERENCIAS

[1] M. Zeinali, L. Ramezani Asli, and M. A. Khalili, "Integrating business intelligence and CRM systems with a machine learning approach for predictive customer retention in e-commerce," *The Scientific World Journal*, vol. 2026, p. 1946904, 2026.

[2] Olist and A. Sionek, "Brazilian e-commerce public dataset by olist," Kaggle, 2018. [Online]. Available: https://www.kaggle.com/datasets/olistbr/brazilian-ecommerce

[3] P. Wangkiat and C. Polprasert, "Machine learning approach to predict e-commerce customer satisfaction score," in *Proc. Int. Conf. on Business and Industrial Research (ICBIR)*. IEEE, 2023.

[4] A.-N. Wong and B. P. Marikannan, "Optimising e-commerce customer satisfaction with machine learning," *Journal of Physics: Conference Series*, vol. 1712, p. 012044, 2020.

[5] M. Zaghloul, S. Barakat, and A. Rezk, "Predicting e-commerce customer satisfaction: Traditional machine learning vs. deep learning approaches," *Journal of Retailing and Consumer Services*, vol. 79, p. 103865, 2024.

[6] R. Orman, "Hybrid deep learning for e-commerce customer satisfaction classification," *Array*, vol. 31, p. 101153, 2026.